

一. 逐句原始数据表字段说明

工作表信息

- 工作表名称：逐句原始数据
- 数据内容：每条记录（行）对应一个句子的指标分析结果

字段详细说明

1. 标号（A 列）

- 含义：所有句子的唯一标识符
- 格式：从 1 开始的连续编号（1-N）

2. 主题（B 列）

- 含义：该句子所属的主题领域
- 示例：碳达峰、工业领域、城乡建设领域等

3. File（C 列）

- 含义：该句子所属的源文件名
- 示例：2030 年前碳达峰行动方案.docx、上海市碳达峰实施方案.docx

4. Query（D 列）

- 含义：作为参照基准的具体句子
- 特点：
 - 同一主题下，所有文件的 query 内容完全一致
 - 对应中央文件（如《2030 年前碳达峰行动方案》）的逐句分句结果
- 作用：不同地方以同一篇中央文件作为参照，建立统一的比较基准，确保不同地方文件的可比性

示例说明：

标号	主题	file	query
1	碳达峰	2030年前碳达峰行动方案.docx	2030年前碳达峰行动方案为深入贯彻落实党中央、国务院关于碳达峰、碳中和的重大战略决策，扎实推进碳达峰行动，制定本方案
2	碳达峰	2030年前碳达峰行动方案.docx	（一）指导思想
3	碳达峰	2030年前碳达峰行动方案.docx	以习近平新时代中国特色社会主义思想为指导，全面贯彻党的十九大和十九届二中、三中、四中、五中全会精神，深入贯彻习近平生态文明思想，立足新发展阶段，完整、准确、全面贯彻新发展理念，构建新发展格局，坚持系统观念，处理好发展和减排、整体和局部、短期和中长期的关系，统筹稳增长和调结构，把碳达峰、碳中和纳入经济社会发展全局，坚持“全国统筹、节约优先、双轮驱动、内外畅通、防范风险”的总方针，有力有序有效做好碳达峰工作，明确各地区、各领域、各行业目标任务，加快实现生产生活方式绿色变革，推动经济社会发展建立在资源高效利用和绿色低碳发展的基础之上，确保如期实现2030年前碳达峰目标
4	碳达峰	2030年前碳达峰行动方案.docx	（二）工作原则
5	碳达峰	2030年前碳达峰行动方案.docx	——总体部署、分类施策
6	碳达峰	2030年前碳达峰行动方案.docx	坚持全国一盘棋，强化顶层设计和各方统筹
7	碳达峰	2030年前碳达峰行动方案.docx	各地区、各领域、各行业因地制宜、分类施策，明确既符合自身实际又满足总体要求的目标任务

.....

342	碳达峰	上海市碳达峰实施方案.docx	2030年前碳达峰行动方案为深入贯彻落实党中央、国务院关于碳达峰、碳中和的重大战略决策，扎实推进碳达峰行动，制定本方案
343	碳达峰	上海市碳达峰实施方案.docx	（一）指导思想
344	碳达峰	上海市碳达峰实施方案.docx	以习近平新时代中国特色社会主义思想为指导，全面贯彻党的十九大和十九届二中、三中、四中、五中全会精神，深入贯彻习近平生态文明思想，立足新发展阶段，完整、准确、全面贯彻新发展理念，构建新发展格局，坚持系统观念，处理好发展和减排、整体和局部、短期和中长期的关系，统筹稳增长和调结构，把碳达峰、碳中和纳入经济社会发展全局，坚持“全国统筹、节约优先、双轮驱动、内外畅通、防范风险”的总方针，有力有序有效做好碳达峰工作，明确各地区、各领域、各行业目标任务，加快实现生产生活方式绿色变革，推动经济社会发展建立在资源高效利用和绿色低碳发展的基础之上，确保如期实现2030年前碳达峰目标
345	碳达峰	上海市碳达峰实施方案.docx	（二）工作原则
346	碳达峰	上海市碳达峰实施方案.docx	——总体部署、分类施策
347	碳达峰	上海市碳达峰实施方案.docx	坚持全国一盘棋，强化顶层设计和各方统筹
348	碳达峰	上海市碳达峰实施方案.docx	各地区、各领域、各行业因地制宜、分类施策，明确既符合自身实际又满足总体要求的目标任务

- 碳达峰主题下，《2030 年前碳达峰行动方案》和《上海市碳达峰实施方案》的 query 完全相同
- 中央文件（标号 1-341）与上海文件（标号 342-682）的 query 一一对应，均为中央文件的分句结果

5. Match (E 列)

- 含义：基于 SBERT 相似度计算，在 File 文件中与 query 最相似的句子
- 技术：使用 Sentence-BERT 模型计算语义相似度

6. Query_structure (F 列)

- 含义：query 句子在中央文件中的段落位置信息
- 作用：标识句子在原文中的结构层级和归属

7. Match_structure (G 列)

- 含义：match 句子在 File 文件中的段落位置信息
- 作用：标识匹配句子在地方文件中的结构位置

8. Direct_sim (H 列)

- 含义：query 与 match 之间的语义相似度得分

- 范围：0-1 之间的数值，越接近 1 表示相似度越高
- 作用：量化中央与地方文件内容的相似程度

9. Direct_degree (I 列)

- 含义：match 与 query 的相对语调差异
- 计算方式：match 的语义程度总分 - query 的语义程度总分
- 解读：
 - 正值：match 比 query 语气更强
 - 负值：match 比 query 语气较弱
 - 零值：语气程度相当
 - 词典：具体的语义值参考语义词典中的打分（[语义词典表](#)）

数据关系说明

本质是：以中央文件为基准，横向比较各地方文件的对应内容。

- 纵向关系：同一文件内句子的顺序结构
- 横向关系：不同文件间相同 query 的对比分析
- 分析维度：通过相似度(direct_sim)和语调差异(direct_degree)量化地方文件对中央文件的相似程度和相对语调

二、文件聚合数据表字段说明

工作表信息

- 工作表名称：文件聚合数据
- 数据内容：每条记录（行）对应一个文件的指标分析结果

字段详细说明

1. fields (A 列)

- 含义：该文件所属的主题
- 示例：碳达峰、工业领域、城乡建设领域等

2. id (B 列)

- 含义：该文件的唯一标识符

- 格式：1-168

3. 地区 (C 列)

- 含义：文件所在的地区
- 示例：中央（2030 年前碳达峰行动方案）；上海（上海市碳达峰实施方案）

4. file (D 列)

- 含义：具体的文件名

5. 时间 (E 列)

- 含义：每篇文件的发布时间
- 格式：YYYY/MM/DD

6. avg_direct_sim (F 列)

- 含义：逐句原始数据中该 file 文件所有句子的 direct_sim 平均值
- 示例：2030 年前碳达峰行动方案的 avg_direct_sim 为 1，是通过对逐句原始数据中该文件对应的第 1-341 号句子的 direct_sim 值求平均得到的(因为中央和中央自己参照的相似度肯定是 1)

7. avg_direct_degree (G 列)

- 含义：逐句原始数据中该 file 文件所有句子的 direct_degree 平均值
- 示例：2030 年前碳达峰行动方案的 avg_direct_degree 为 0，是通过对逐句原始数据中该文件对应的第 1-341 号句子的 direct_degree 值求平均得到的（中央和中央自己的语调肯定是一致的）

8. 0.25 (H 列)

- 含义：逐句原始数据中该 file 文件所有相似度高于 0.25 的句子的 direct_degree 平均值
- 解释：和 avg_direct_degree 是同一类指标，只是这里做了一定程度上相似度的控制，这里相似度阈值越高，理论上语义指标值会越稳健；后面的 0.5/0.75 也是同样的目的

8. 0.5 (I 列)

- 含义：逐句原始数据中该 file 文件所有相似度高于 0.5 的句子的 direct_degree 平均值

8. 0.75 (J 列)

- 含义：逐句原始数据中该 file 文件所有相似度高于 0.75 的句子的 direct_degree 平均值